

SAM2 논문 리뷰

“SAM 2: Segment Anything in Images and Videos”

삼성사와 아이들

김현진, 이문용, 김재현, 어지유

2025.10.14

목차

- 1 SAM 이전 Segmentation Model 한계
- 2 SAM
- 3 SAM2
- 4 SAM2 구조
- 5 SAM2 코드 구현

기존 Segmentation Model의 한계


고정된 클래스 기반 분류 → 사전 정의된 클래스만 인식, 새로운 객체 일반화 불가

대규모 라벨링 의존 → 픽셀 단위 수작업 필요, 데이터 구축 비용 과다

도메인 특화 재학습 필요 → 도메인 바뀌면 성능 급락, 재학습 필수

상호작용 불가 → 한 번의 예측으로 결과 고정, 사용자 피드백 반영 불가


SAM 개요 – Task: promptable segmentation



(a) **Task:** promptable segmentation

- Task: 점·박스·텍스트 등 프롬프트로 원하는 객체를 지정
- 모델이 그 영역을 자동으로 세그멘테이션
- 클래스 라벨을 정하지 않아도, 프롬프트만으로 객체를 구분


SAM 개요 – Data: SA-1B & Data Engine



(c) **Data:** data engine (top) & dataset (bottom)

- SAM은 SA-1B (11M 이미지, 1B 마스크) 데이터셋으로 학습됨
- 모델이 주석을 돕고, 사람이 검수하는 데이터 루프 구조로 구축
- 데이터 엔진 3단계: (1) 모델보조 수동 → (2) 반자동 → (3) 자동 생성
- 대규모 데이터 확장을 통해 Zero-shot 일반화 성능 확보

SAM 개요 – Model: Image/Prompt Encoder + Fast Mask Decoder




(b) **Model:** Segment Anything Model (SAM)

- 구성: Image Encoder, Prompt Encoder, Mask Decoder로 이루어진 구조
- 특징: 프롬프트만 바꿔 여러 객체를 실시간 세그멘테이션 가능

SAM 구조

07



입력 전처리 : 원본 이미지를 1024×1024 로 정규화
→ 비율 유지 리사이즈 → 남은 영역 0으로 패딩 → 채널별 mean/std 정규화

패치 분할 : 이미지를 16×16 픽셀 단위로 분할 → 총 $64 \times 64 = 4096$ 개 패치 생성


패치 임베딩 : 각 패치를 $768 \rightarrow 1280$ 차원으로 선형 변환 (Linear Projection) → 패치당 하나의 토큰(Token) 생성

포지셔널 임베딩 추가 : 각 토큰에 절대 + 상대 위치 임베딩 (Absolute/Relative Positional Encoding) 더함 → 공간적 위치 정보 부여

ViT-H Transformer 인코딩 : 총 32개의 Transformer Block
각 블록 = LayerNorm → Multi-Head Self-Attention → MLP → Residual

Neck 블록 : Conv → Norm → Residual 구조 1280차원 → 256차원 축소
→ 최종 임베딩 맵 형태: $64 \times 64 \times 256$

출력 : 마스크 디코더로 전달되는 최종 이미지 임베딩
(프롬프트 인코더와 결합되어 마스크 생성됨)



- 시간축 부재: 프레임 간 일관성/기억 없음 → 영상에선 드리프트·가려짐 후 재등장에 취약
- 반복 상호작용 비용: 긴 영상에서 프레임마다 재클릭 필요

- 빠른 움직임·블러·작은 객체: 격변 장면에서 품질 흔들림
- 모호한 프롬프트: 하나의 클릭/박스가 여러 객체에 해당하면 결과가 다중 마스크로 분기

SAM2 개요 – Task: Promptable Video Segmentation

video & prompts in one or multiple frames



box

(skipped)

points

mask

model




object segmentation throughout the video

(a) Task: promptable visual segmentation

- 입력 : 프롬프트(박스/포인트/마스크) + 영상 프레임
- 목표 : 프롬프트된 객체를 전 프레임에서 추적·분할(유효 마스크)
- 방식 : 첫 프레임 초기화 → 프레임 진행하며 마스크 전파 → 필요 시 클릭 보정
- 효과 : 클릭 수 절감, 프레임 간 일관성 확보(이후 SAM2의 메모리로 강화)
- 출력 : 프레임별 객체 마스크(필요 시 복수 후보 + 점수)


SAM2 개요 – Data: SA-V & Data Engine



- SA-V 통계: 642.6K masklets, 35.5M masks, 50.9K videos, 196h
- 데이터 엔진: (1) 모델 보조 수동 → (2) 반자동 → (3) 자동 생성 (모델-인-더-루프)
- 효과: 대규모·다양한 영상으로 일반화와 장면/속도 변화 대응력 강화

(c) Data: data engine and dataset


SAM2 개요 – Model: Image/Prompt/Mask + Memory



(b) Model: Segment Anything Model 2


- 구성: Image Encoder + Prompt Encoder + Mask Decoder + Memory Attention/Bank
- 핵심: 이전 프레임의 마스크/특징을 Memory Bank에 저장 → 현재 프레임에서 Memory Attention으로 읽어 재식별/재붙잡기 → 드리프트 감소
- 상호작용: 프롬프트만 갱신해도 마스크 즉시 갱신(임베딩 재사용)
- 출력: 여러 후보 마스크 + IoU score 동시 제공(최적 선택 가이드)

SAM2 구조




- 이미지 인코더(Hiera) - MAE 사전학습 기반의 계층적 인코더 (Hiera Backbone) 사용
다단계 다운샘플과 Q-Pooling으로 효율적 특징 압축
- 멀티스케일 특징 활용 - 인코더의 stride 4·8 피처를 Mask Decoder에 직접 skip 연결
- Memory Attention 구조 - Self + Cross Attention + MLP로 구성
Memory Bank로부터 과거 image/mask 특징 불러와 보강
- 포지셔널 임베딩(RoPE) - 절대 + 2D 상대 RoPE 임베딩으로 위치 정보 강화
- Occlusion Head - 가려짐(occlusion) 영역까지 예측하는 보조 헤드 추가
- Skip Connection (High-res 보존) - 인코더 고해상도 피처를 Decoder에 직접 전달해 세밀도 향상
- Memory Encoder 후처리 - 예측 마스크 + 이미지 임베딩 → Conv 요약 → Memory Bank 저장

SAM2 Image Encoder: Hiera-B+




- 이미지를 패치 단위로 분할해 입력
- 계층 구조(Q-Pooling)로 효율적 특징 압축
- 멀티스케일 특징 추출로 세밀·전역 정보 동시 학습
- Global / Local Attention 병행으로 정밀도 향상
- 결과 피쳐는 디코더로 전달돼 최종 시각 표현 생성

SAM2 Mask Decoder



- 구조: SAM과 유사 + 업샘플 때 stride 4/8 특징 스킵 결합
- 교차 주고받기: image ↔ token attention (self/이
미지 → 토큰 / 토큰 → 이미지)로 세부 경계 정교화
- 포인터: mask token = object pointer (대상 위치 힌트)
- 판별 헤드: IoU score · occlusion score
예측 → 여러 후보 중 최적 마스크 선택

SAM2 상호작용 기반 세그멘테이션 과정



- 초기화: 첫 프레임에 박스/포인트로 대상 지정 → 마스크 시작
- 전파: 메모리로 다음 프레임들에 일관 마스크 전파
- 보정: 오류 프레임에서 클릭 보정 → 메모리 갱신 → 이후 프레임 재붙잡기/드리프트 감소

```
class SAM2MultiPersonSegmentation:
    def __init__(self, checkpoint_path):
        """
        SAM2 기반 다중 인물 세그멘테이션

        Args:
            checkpoint_path: SAM2 체크포인트 경로
        """
        self.device = "cuda" if torch.cuda.is_available() else "cpu"
        print(f"Using device: {self.device}")

        # SAM2 Predictor 초기화 (간단한 방법)
        self.predictor = SAM2ImagePredictor.from_pretrained(
            checkpoint_path,
            device=self.device
        )
        print("SAM2 모델 로드 완료!")

    def segment_auto(self, image_path, num_people=5):
        """
        그리드 기반 자동 세그멘테이션 (개선 버전)

        Args:
            image_path: 입력 이미지 경로
            num_people: 추출할 인물 수


        Returns:
            masks: 개별 마스크 리스트
            image: 원본 이미지
        """
        # 이미지 로드
        image = cv2.imread(image_path)
        image = cv2.cvtColor(image, cv2.COLOR_BGR2RGB)

        self.predictor.set_image(image)

        print("자동 세그멘테이션 실행 중...")

        # 더 촘촘한 그리드 생성 (사람 위치에 집중)
        h, w = image.shape[:2]
```


코드 구현



References

Ravi, N., Gabeur, V., Hu, Y.-T., Hu, R., Ryali, C., Ma, T., et al. (2024).
Segment Anything in Images and Videos (SAM2).
arXiv preprint arXiv:2408.00714.

Ryali, C., Bolya, D., Dai, X., Feichtenhofer, C. (2023).
Hiera: A Hierarchical Vision Transformer without the Bells-and-Whistles.
arXiv preprint arXiv:2306.00989.

Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T.,
Whitehead, S., Berg, A. C., Lo, W.-Y., Dollár, P., & Girshick, R. (2023). Segment
Anything. arXiv preprint arXiv:2304.02643.

감사합니다